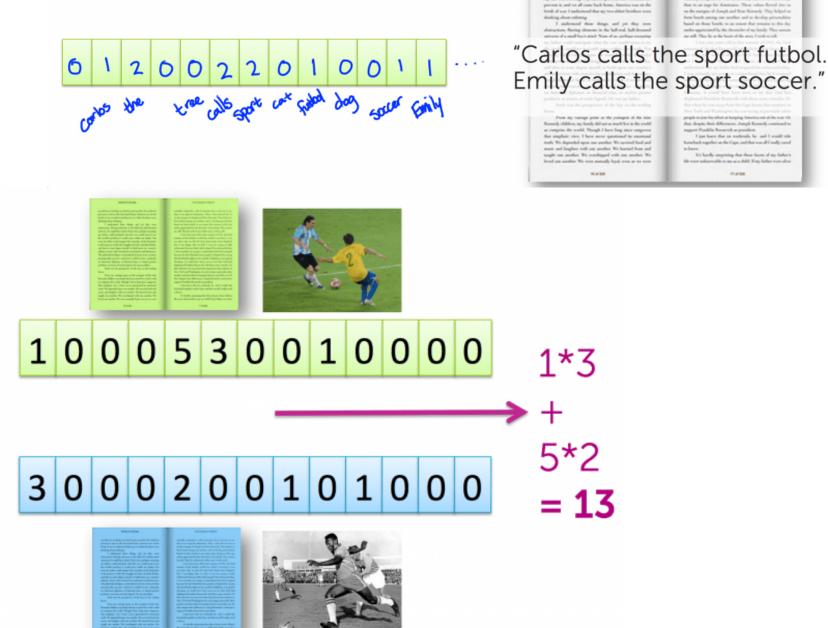
텍스트 유사도



유사도 측정



Street M. Squared

N-gram 모델

언어 모델(Language Model) 에서 사용되는 횟수 기반의 벡터 표현방식(Count-based representation) 입니다.

■ N-gram

N=1:1-gram(unigram)

N=2:2-gram(bigram)

N=3: 3-gram(trigram)

■ N=4:4-gram

$$similarity = \frac{tf(A, B)}{tokens(A)}$$

N = 1: This is a sentence unigrams: this, is, a, sentence

N = 2: This is a sentence bigrams: this is, is a, a sentence

N = 3: This is a sentence trigrams: this is a, is a sentence

■ N-grams 단점

■ N-gram은 장기 의존성(Long-term dependency) 이 없습니다. N-gram에서는 일부 단어 시퀀스의 횟수만을 가지고 판단하기 때문에 문장 앞쪽의 문맥을 고려하지 않은 채 토큰을 선택하게 됩니다.

N-gram 모델

text_similarity.ipynb

```
# 어절 단위 n-gram
def word ngram(bow, num gram):
    text = tuple(bow)
    ngrams = [text[x:x + num gram] for x in range(0, len(text))]
    return tuple(ngrams)
# 음절 n-gram 분석
def phoneme ngram(bow, num gram):
    sentence = ' '.join(bow)
    text = tuple(sentence)
    slen = len(text)
    ngrams = [text[x:x + num_gram] for x in range(0, slen)]
    return ngrams
```

N-gram 모델

```
# 유사도 계산

def similarity(doc1, doc2):
    cnt = 0
    for token in doc1:
        if token in doc2:
        cnt = cnt + 1

return cnt/len(doc1)
```

$$similarity = \frac{tf(A, B)}{tokens(A)}$$

단어/문자을 벡터로 표현하면, 벡터간 거리나 각도를 이용해 유사성을 파악할 수 있다.

- 출현빈도로 유사도를 계산하면 동일한 단어가 많이 포함 될수록 벡터의 크기가 커집니다.
- 코사인 유사도는 벡터의 크기와 상관없이 결과 값이 안정적입니다.

$$similarity = \cos\theta = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^{n} A_i \times B_i}{\sqrt{\sum_{i=1}^{n} (A_i)^2} \times \sqrt{\sum_{i=1}^{n} (B_i)^2}}$$

```
def cos_sim(vec1, vec2):
    return dot(vec1, vec2) / (norm(vec1) * norm(vec2))
```

```
# TDM 만들기
def make term doc mat(sentence bow, word dics):
    freq mat = {}
    for word in word dics:
        freq mat[word] = 0
    for word in word dics:
        if word in sentence bow:
            freq mat[word] += 1
    return freq mat
# 단어 벡터 만들기
def make vector(tdm):
   vec = []
   for key in tdm:
        vec.append(tdm[key])
    return vec
```

```
# 단어 묶음 리스트를 하나로 합침
bow = bow1 + bow2 + bow3
# 단어 묶음에서 중복제거해 단어 사전 구축
word_dics = []
for token in bow:
  if token not in word_dics:
     word_dics.append(token)
# 문장 별 단어 문서 행렬 계산
freq_list1 = make_term_doc_mat(bow1, word_dics)
freq_list2 = make_term_doc_mat(bow2, word_dics)
freq_list3 = make_term_doc_mat(bow3, word_dics)
# 코사인 유사도 계산
doc1 = np.array(make_vector(freq_list1))
doc2 = np.array(make_vector(freq_list2))
doc3 = np.array(make_vector(freq_list3))
r1 = cos_sim(doc1, doc2)
r2 = cos_sim(doc3, doc1)
print(r1, r2)
```

TF-IDF

```
from sklearn.feature extraction.text import TfidfVectorizer
sentence = ( "휴일 인 오늘 도 서쪽 을 중심 으로 폭염 이 이어졌는데요, 내일 은 반가운 비 소
식 이 있습니다.", "폭염 을 피해서 휴일 에 놀러왔다가 갑작스런 비 로 인해 망연자실 하고 있습니다.")
tfidf vectorizer = TfidfVectorizer()
# 문장 벡터화
tfidf_matrix = tfidf_vectorizer.fit_transform(sentence)
# 각 단어
text = tfidf vectorizer.get feature names()
# 각 단어의 벡터 값
idf = tfidf vectorizer.idf
                                       {'갑작스런': 1.4054651081081644, '내일': 1.4054651081081644, '놀러왔다가': 1.4054651081081644, '망
                                       연자실': 1.4054651081081644, '반가운': 1.4054651081081644, '서쪽': 1.4054651081081644, '소식':
                                       1.4054651081081644, '오늘': 1.4054651081081644, '으로': 1.4054651081081644, '이어졌는데요':
print(dict(zip(text, idf)))
                                       1.4054651081081644, '인해': 1.4054651081081644, '있습니다': 1.0, '중심': 1.4054651081081644, '폭염':
                                       1.0, '피해서': 1.4054651081081644, '하고': 1.4054651081081644, '휴일': 1.0}
```

자카드 유사도(Jaccard Similarity)

두 문장을 각각 단어의 집합으로 만든 뒤 두 집합을 통해 유사도를 측정하는 방식 중 하나

- 유사도를 측정하는 방법은 두 집합의 교집합인 공통된 단어의 개수를 두 집합의 합집합, 전체 단어의 갯수로 나눈다.
- 결과값은 공통의 원소의 개수에 따라 0과 1사이의 값이 나올 것이고, 1에 가까울수록 유사도가 높다

$$J(A,B) = \frac{|A \cap B|}{|A \cup B|} = \frac{|A \cap B|}{|A| + |B| - |A \cap B|}.$$

코사인 유사도는 사이킷런에서 유사도 측정을 위한 함수를 제공합니다.

$$similarity = \cos\theta = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^{n} A_i \times B_i}{\sqrt{\sum_{i=1}^{n} (A_i)^2} \times \sqrt{\sum_{i=1}^{n} (B_i)^2}}$$

from sklearn.metrics.pairwise import cosine_similarity

cosine_similarity(tfidf_matrix[0:1], tfidf_matrix[1:2])

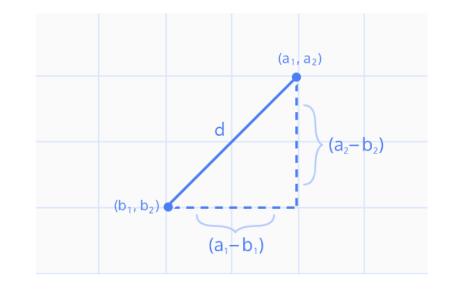
첫 번째 문장

두 번째 문장

유클리디언 유사도 (L2 Distance)

가장 기본적인 거리를 측정하는 유사도 공식입니다. 유클리디언 거리 = L2 거리: N차원 공간에서 두 점 사이의 최단 거리를 구하는 접근법

$$\sqrt{(p_1-q_1)^2+\;(p_2-q_2)^2+\;...+\;(p_n-q_n)^2}=\sqrt{\sum_{i=1}^n(p_i-q_i)^2}$$

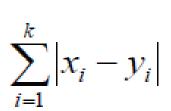


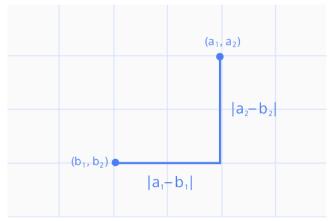
from sklearn.metrics.pairwise import euclidean_distances

euclidean_distances(tfidf_matrix[0:1], tfidf_matrix[1:2])

맨하탄 유사도 (L1 Distance)

맨하탄 거리를 통해 유사도를 측정하는 방법으로, 맨하탄 거리 = L1 거리 입니다.



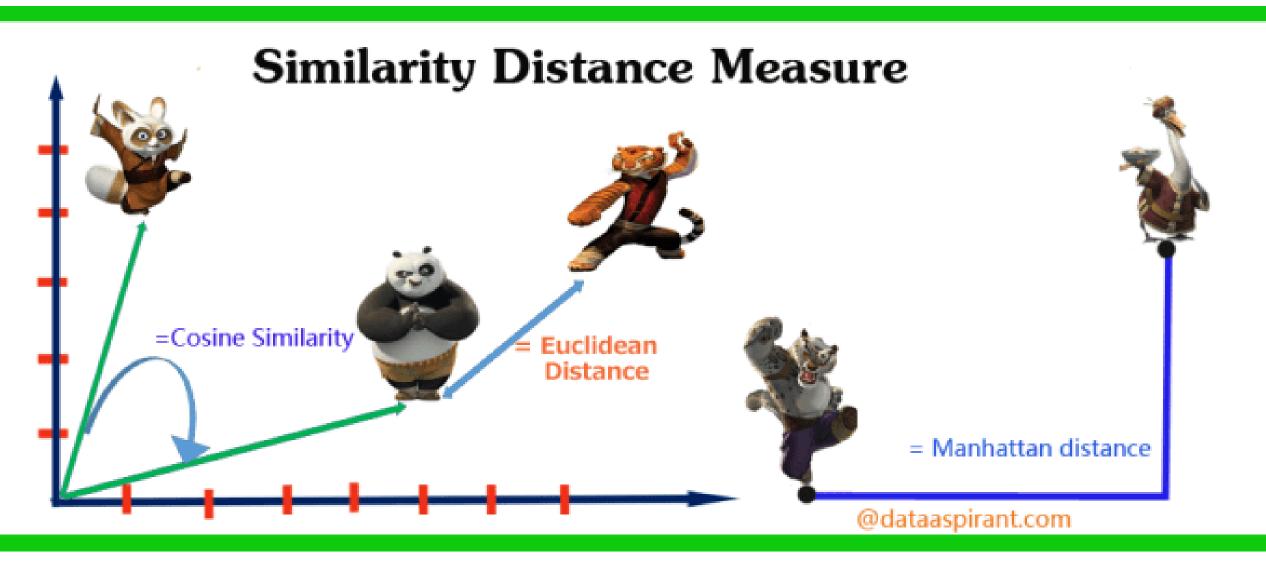


from sklearn.metrics.pairwise import manhattan_distances

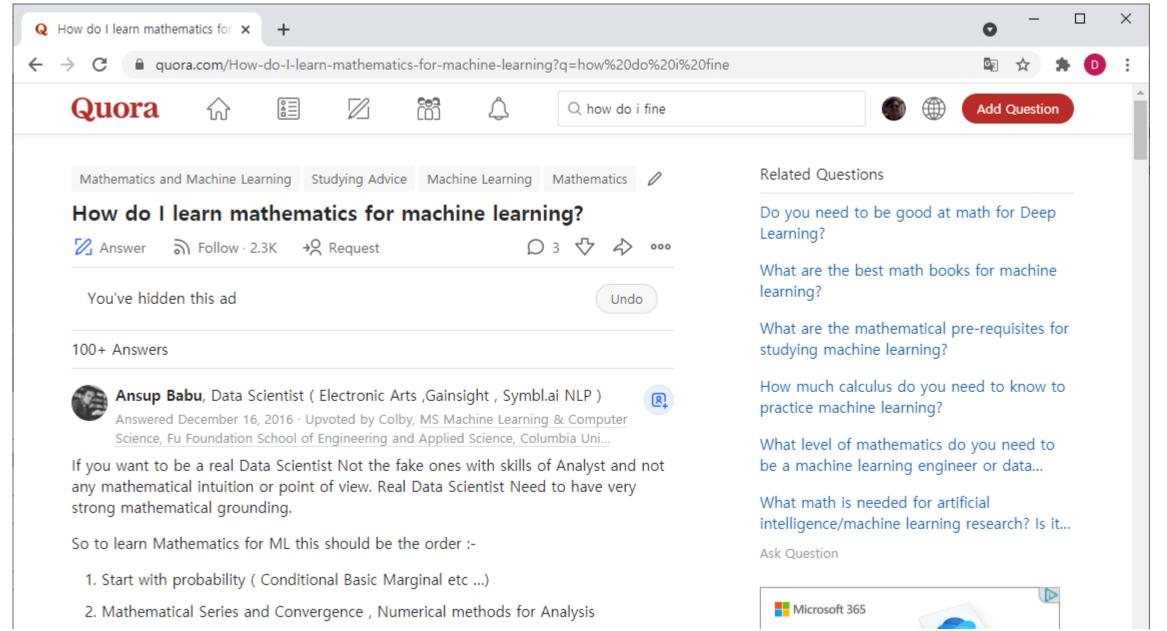
```
def I1_normalize(v):
    norm = np.sum(v)
    return v / norm
```

L1 정규화

tfidf_norm_I1 = I1_normalize(tfidf_matrix) manhattan_distances(tfidf_norm_I1[0:1], tfidf_norm_I1[1:2])



Quora Question Pairs 유사도 측정



Quora Question Pairs 유사도 측정

■ kagge 가입 및 kgggle.json 다운로드

- kaggle 가입 : https://www.kaggle.com/
- kgggle.json 다운로드 : https://www.kaggle.com/<username>/account

API

Using Kaggle's beta API, you can interact with Competitions and Datasets to download data, make submissions, and more via the command line. Read the docs



Expire API Token

■ 데이터 필드

- 데이터: Quora Question Pairs, https://www.kaggle.com/c/quora-question-pairs/
- 데이터 필드: id, qid1, qid2, question1, question2, is_duplicate(1-두개의 질문이 중복, 0 두개의 질물이 중복 아님)



Quora Question Pairs 유사도 측정



quora_preprocessing.ipynb

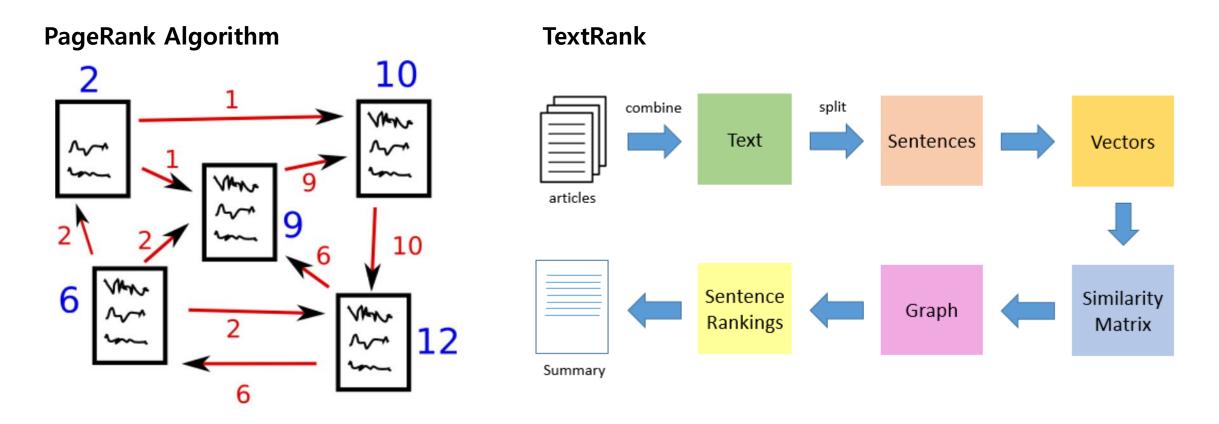
quora_similarity_xgboost.ipynb

quora_similarity_cnn.ipynb

참고 : 텐서플로 2와 머신러닝으로 시작하는 자연어 처리

Text Summarization

https://github.com/prateekjoshi565/textrank_text_summarization



Thank you